

Aprendizaje de Máquina Aplicado — EAFIT

Predicción de aceptación de depósito en campañas de marketing bancario

Entrega 3 de 3: Modelo final, interpretación y comunicación de hallazgos

Estudiantes: Ana Sofía Rodríguez · Mariana Gutiérrez · Esteban Giraldo

Dataset: Bank Marketing (UCI Machine Learning Repository)

Tarea: Clasificación binaria supervisada

Fecha: Mayo de 2026

Resumen

Este trabajo presenta el modelo final de predicción de aceptación de depósito a término en campañas de marketing bancario, desarrollado a lo largo de tres entregas bajo el marco CRISP-DM. Se emplea el dataset Bank Marketing (UCI, 45,211 registros), con clasificación binaria supervisada sobre 14 variables predictoras (excluyendo `duration` por *data leakage*).

El modelo seleccionado es **LightGBM con `is_unbalance=True` (`class_weight`)** y umbral de decisión ajustado a 0.689, resultante de una comparación experimental entre tres familias de modelos y nueve configuraciones de manejo de desbalance (Entrega 2). Los resultados finales sobre el conjunto de prueba independiente son: **ROC-AUC = 0.7871**, **F1-score = 0.4787**, Recall = 0.4509 y Precision = 0.5102.

El análisis SHAP identifica el tipo de contacto, el balance bancario, el número de contactos en la campaña y el resultado de campañas previas como los factores más determinantes. El objetivo inicial de ROC-AUC > 0.85 no se alcanzó con el conjunto de *features* disponible sin `duration`; se discuten las causas técnicas y las acciones necesarias para cerrar esa brecha.

Índice

1	Introducción y formulación del problema	3
1.1	Contexto y motivación	3
1.2	Formulación formal	3
1.3	Resumen del recorrido experimental	3
2	Metodología Final	3
2.1	Configuración del modelo	4
2.2	Esquema de validación	4
2.3	Registro de decisiones metodológicas	5
3	Resultados	5
3.1	Desempeño en validación cruzada	5
3.2	Evaluación final sobre el conjunto de prueba	6
3.3	Progresión a lo largo de las entregas	8
4	Interpretabilidad — Análisis SHAP	8
4.1	¿Por qué SHAP?	8
4.2	Variables más importantes — importancia global	9
4.3	Patrones clave identificados por SHAP	11
5	Análisis de Sensibilidad	12
5.1	Curvas de aprendizaje	12
5.2	Sensibilidad al umbral de decisión	13
6	Análisis de Errores	14
6.1	Distribución de tipos de predicción	14
6.2	Perfil de los Falsos Negativos	14
7	Discusión	16
7.1	¿Cuál es el mejor modelo y por qué?	16
7.2	¿Qué tan confiables son los resultados?	16
7.3	¿Qué variables o patrones explican el desempeño?	17
8	Conclusiones y Recomendaciones	17
8.1	Conclusiones del proyecto	17
8.2	¿Qué haría falta para mejorar la solución?	18

1 Introducción y formulación del problema

1.1 Contexto y motivación

Las campañas de marketing bancario por contacto telefónico representan un costo operativo significativo. Predecir qué clientes tienen mayor probabilidad de aceptar una oferta de depósito a plazo fijo permite priorizar contactos, reducir costos y mejorar la tasa de conversión. Este proyecto aborda ese problema bajo el marco CRISP-DM en tres entregas progresivas.

1.2 Formulación formal

Campo	Detalle
Tarea	Clasificación binaria supervisada
Variable objetivo	$y \in \{\text{yes}, \text{no}\}$; positivo = acepta depósito
Métrica principal	ROC-AUC (independiente del umbral, robusta al desbalance)
Métrica secundaria	F1-score (desempeño en clase minoritaria)
Dataset	Bank Marketing UCI — 45,211 registros, 14 <i>features</i>
Desbalance	88% no / 12% yes
Exclusión	<code>duration</code> eliminada por <i>data leakage</i>

Cuadro 1: Ficha de formulación del problema

1.3 Resumen del recorrido experimental

El proyecto evolucionó en tres etapas: **Entrega 1** estableció la formulación del problema, el EDA y dos baselines reproducibles (DummyClassifier y Logistic Regression). **Entrega 2** comparó tres familias de modelos en nueve configuraciones de desbalance, identificando `LightGBM + class_weight` como la más prometedora. **Entrega 3** (este documento) presenta la evaluación final, el análisis SHAP, el análisis de sensibilidad y las conclusiones del proyecto.

2 Metodología Final

2.1 Configuración del modelo

Componente	Configuración
Algoritmo	LGBMClassifier (n_estimators=300, is_unbalance=True)
Desbalance	is_unbalance=True (equivalente a class_weight='balanced')
Preprocesamiento	StandardScaler (numéricas) + OneHotEncoder (categóricas)
Pipeline	sklearn.Pipeline para prevenir <i>data snooping</i>
Umbral de decisión	0.6892 — calculado sobre hold-out interno de X_train con el mismo modelo ya entrenado sobre X_train completo, maximizando F1 en curva PR
Random state	42 (reproducibilidad completa)

Cuadro 2: Configuración del modelo final

2.2 Esquema de validación

La validación se realizó en dos capas: **5-fold CV estratificada** sobre el conjunto de entrenamiento (36,168 registros) para selección del modelo, y **evaluación final única** sobre el conjunto de prueba (9,043 registros) para reporte de métricas definitivas. El umbral óptimo se calculó sobre un *hold-out* interno de X_train (20%) a partir de la curva Precision-Recall, sin acceder al test.

2.3 Registro de decisiones metodológicas

Decisión		Qué se hizo	Justificación y evidencia
Exclusión duration	de	Variable eliminada antes de la división train/test	Solo observable post-llamada; infla ROC-AUC +18.7 pp (Entrega 2, Capa 2)
División estratificada	80/20	<code>train_test_split</code> con <code>stratify=y</code> , <code>random_state=42</code>	Preserva proporción 88/12; semilla garantiza reproducibilidad
Validación cruzada 5-fold		<code>StratifiedKFold(n=5)</code> sobre <code>X_train</code>	Estima desempeño generalizable; <code>std < 0.01</code> confirma estabilidad
Selección LightGBM	de	Comparación de 3 familias en CV (Entrega 2)	Mayor ROC-AUC y F1; manejo nativo de desbalance; más eficiente que RF
<code>class_weight</code> vs SMOTE	vs	<code>is_unbalance=True</code> en LightGBM	F1 = 0.4535 vs SMOTE F1 = 0.3822 en CV; sin riesgo de leakage por oversampling
Umbral óptimo 0.689		Curva PR sobre validación interna	Con desbalance 88/12 el umbral 0.5 favorece la clase mayoritaria
ROC-AUC métrica principal	como	ROC-AUC para comparar; F1 como complementaria	DummyClassifier obtiene Accuracy = 0.88 sin aprender nada

Cuadro 3: Registro auditables de decisiones metodológicas

3 Resultados

3.1 Desempeño en validación cruzada

Métrica	Media 5-fold	($\pm$ std)	Interpretación
ROC-AUC	0.7831	(0.0048)	Capacidad discriminativa global
F1-score	0.4535	(0.0032)	Balance precisión-recall (clase <code>yes</code>)
Accuracy	0.8365	(0.0048)	Referencia (sesgada hacia clase mayoritaria)
Precision	0.3726	(0.0079)	De los predichos como <code>yes</code> , el 37% lo son
Recall	0.5798	(0.0138)	Detecta el 58% de los clientes realmente interesados

Cuadro 4: Desempeño del modelo final en 5-fold CV estratificada sobre `X_train`

La desviación estándar entre pliegues es menor a 0.01 en todas las métricas, confirmando que el modelo es **estable** ante distintas particiones del conjunto de entrenamiento.

3.2 Evaluación final sobre el conjunto de prueba

Métrica	Test (umbral 0.689)	Coherencia con CV
ROC-AUC	0.7871	0.7831 en CV ($\Delta = +0.0040$)
F1-score	0.4787	0.4535 en CV ($\Delta = +0.0252$)
Recall	0.4509	0.5798 en CV (esperado: más bajo con umbral alto)
Precision	0.5102	0.3726 en CV (esperado: más alto con umbral alto)
Accuracy	0.8851	0.8365 en CV

Cuadro 5: Métricas finales sobre el conjunto de prueba independiente. La coherencia entre CV y test confirma ausencia de *overfitting*.

Clase	Precision	Recall	F1	Soporte
no (0)	0.93	0.94	0.94	7,985
yes (1)	0.51	0.45	0.48	1,058
Macro avg	0.72	0.70	0.71	9,043
Weighted avg	0.88	0.89	0.88	9,043

Cuadro 6: Reporte de clasificación completo sobre test




Figura 1: Izquierda: curva ROC del modelo final (AUC = 0.7871). Derecha: curva Precision-Recall con el umbral óptimo marcado (0.689).




Figura 2: Matriz de confusión sobre el conjunto de prueba (umbral = 0.689). TP: 477, TN: 7,527, FP: 458, FN: 581.

3.3 Progresión a lo largo de las entregas

Modelo	ROC-AUC	F1	Recall	Precision	Accuracy
DummyClassifier (Entrega 1)	0.5000	0.0000	0.0000	0.0000	0.8830
Logistic Regression (Entrega 2)	0.7717	0.2815	0.1786	0.6632	0.8933
LightGBM + class_weight (Final)	0.7871	0.4787	0.4509	0.5102	0.8851

Cuadro 7: Progresión del desempeño a lo largo de las tres entregas (evaluación sobre test)




Figura 3: Evolución de ROC-AUC y F1-score desde el DummyClassifier hasta el modelo final. El modelo final mejora el F1 en +0.479 respecto al piso absoluto.

4 Interpretabilidad — Análisis SHAP

4.1 ¿Por qué SHAP?

SHAP (*SHapley Additive exPlanations*) asigna a cada variable un valor que representa cuánto contribuyó a que el modelo predijera lo que predijo para cada observación. A diferencia de `feature_importances_`, SHAP muestra la **dirección del efecto** (si aumentar la variable sube o baja la predicción) y es comparable entre observaciones individuales y el comportamiento global del modelo. Se empleó `TreeExplainer`, el método específico para modelos basados en árboles (LightGBM, Random Forest, XGBoost), que es exacto y significativamente más rápido que el método genérico `KernelExplainer`. Los valores se calcularon sobre una muestra de 1,000 observaciones del conjunto de prueba para eficiencia computacional sin pérdida representativa.

4.2 Variables más importantes — importancia global

Rank	Variable	SHAP medio absol.	Interpretación
1	contact_unknown	0.3216	No saber cómo contactar al cliente es fuertemente negativo
2	day	0.2408	El día del mes tiene alta variabilidad predictiva
3	balance	0.2294	Mayor saldo bancario → mayor propensión
4	campaign	0.1942	Más contactos en la campaña actual → menor aceptación
5	housing_no	0.1626	No tener hipoteca se asocia positivamente
6	contact_cellular	0.1607	Contacto celular tiene efecto positivo vs otras formas
7	poutcome_success	0.1568	Campaña previa exitosa es el predictor más accionable
8	marital_married	0.1395	Estado civil tiene efecto moderado
9	age	0.1300	La edad tiene contribución no lineal
10	pdays	0.1055	Más tiempo desde último contacto → mayor receptividad

Cuadro 8: Top 10 variables por importancia SHAP global (valor absoluto medio)




Figura 4: Importancia global de variables según SHAP (Top 15). Las barras representan el valor absoluto medio de los valores SHAP sobre el conjunto de prueba.




Figura 5: Distribución de valores SHAP (Top 15). Cada punto es una observación del test. El color indica el valor de la variable (rojo = alto, azul = bajo). Los puntos a la derecha aumentan la predicción de `yes`.

4.3 Patrones clave identificados por SHAP

- **Tipo de contacto desconocido reduce drásticamente la probabilidad.** `contact_unknown` es la variable de mayor impacto. Un cliente sin tipo de contacto registrado es casi siempre clasificado como `no`, lo que sugiere que los clientes con información completa tienen perfil cualitativamente distinto.
- **El historial previo es el predictor más accionable.** `poutcome_success` tiene el 7.º

mayor impacto SHAP y su efecto es unidireccional: una campaña previa exitosa siempre aumenta la probabilidad de aceptar. Estratégicamente, re-contactar a estos clientes es la acción de mayor retorno esperado.

- **La fatiga de campaña es real y cuantificable.** `campaign` (número de contactos en la campaña actual) tiene un efecto negativo: a medida que aumenta el número de contactos, el SHAP se vuelve más negativo. Esto confirma que contactar repetidamente a un cliente que no responde reduce, en lugar de aumentar, la probabilidad de éxito.
- **El balance bancario es continuo y no lineal.** Clientes con alto saldo tienen valores SHAP positivos para esta variable, pero el efecto no es lineal; clientes con saldos muy bajos o negativos presentan contribuciones negativas.
- **El día del mes tiene efectos de temporalidad.** `day` aparece como segunda variable más importante, capturando patrones de respuesta según el momento dentro del mes (principios y finales de mes muestran tasas distintas).

5 Análisis de Sensibilidad

5.1 Curvas de aprendizaje




Figura 6: Curvas de aprendizaje — ROC-AUC en función del tamaño del conjunto de entrenamiento. Las bandas representan ± 1 std entre pliegues.

Las curvas de aprendizaje revelan dos hallazgos importantes:

- **Marco interpretativo.** Cuatro escenarios son posibles: si $\text{train} \gg \text{val}$, hay *overfitting*; si ambas curvas son bajas, hay *underfitting*; si val sigue subiendo al final, el modelo se beneficiaría de más datos; si train y val convergen con pocos datos, los datos no son el cuello de botella.
- **Diagnóstico para este modelo.** La brecha entre train y validación es moderada y se cierra progresivamente: no hay *overfitting* severo. A partir de aproximadamente 25,000 muestras, la curva de validación se estabiliza y deja de crecer: más datos no mejorarían el modelo. El techo está determinado por la **calidad informacional de las features disponibles**, lo que explica por qué no se alcanzó $\text{ROC-AUC} > 0.85$ sin *duration*.

5.2 Sensibilidad al umbral de decisión




Figura 7: F1-score, Recall y Precision en función del umbral de decisión. El umbral óptimo (0.689) maximiza F1 y equilibra precisión y recall.

La curva de sensibilidad al umbral muestra el *trade-off* operacional: bajar el umbral aumenta el Recall (detectar más clientes interesados) a costa de bajar la Precision (más llamadas innecesarias). El umbral 0.689, calculado sobre validación interna, representa el equilibrio óptimo según la métrica F1.

Umbral	F1	Recall	Precision	Uso recomendado
< 0.4	Bajo	Alto	Muy bajo	Campañas de volumen (muchos contactos, bajo costo)
0.689 (óptimo)	Max.	0.45	0.51	Balance entre eficiencia y cobertura
> 0.8	Bajo	Bajo	Alto	Campañas de alta calidad (pocos contactos, alto valor)

Cuadro 9: Guía de selección de umbral según contexto operacional

6 Análisis de Errores

6.1 Distribución de tipos de predicción

Con el umbral óptimo de 0.689 sobre el conjunto de prueba (9,043 registros):

Tipo	Cantidad	(%)	Costo operacional
TP (correctos: acepta → predice acepta)	477	5.3%	Conversión capturada
TN (correctos: no acepta → predice no)	7,527	83.2%	Llamadas evitadas
FP (error: no acepta → predice acepta)	458	5.1%	Llamada innecesaria (costo bajo)
FN (error: acepta → predice no)	581	6.4%	Oportunidad perdida (costo alto)

Cuadro 10: Distribución de los 4 tipos de predicción sobre el conjunto de prueba

El número de FN (581) supera al de TP (477) — el modelo pierde más oportunidades de las que captura. Esto es consecuencia del desbalance y refleja el límite del desempeño actual en la clase minoritaria.

6.2 Perfil de los Falsos Negativos

Los Falsos Negativos son los clientes que *sí* aceptarían el depósito pero el modelo predice que no. El análisis por subgrupos categóricos revela qué segmentos de la población presentan tasas de FN sistemáticamente superiores al promedio global (54.9%).

Análisis de errores - Tasa de Falsos Negativos por subgrupo




Figura 8: Tasa de Falsos Negativos (% de clientes con *yes* real clasificados como *no*) segmentada por job, education, marital y outcome. La línea discontinua indica el promedio global (54.9%).

Los hallazgos más relevantes por variable son:

- **job:** Los emprendedores (entrepreneur, $\approx 81\%$) y trabajadores de cuello azul (blue-collar, $\approx 70\%$) presentan las tasas de FN más altas, mientras que retired ($\approx 37\%$) y student ($\approx 36\%$) son los subgrupos que el modelo detecta mejor. La ocupación es el segmentador de error más discriminante.
- **education:** A mayor nivel educativo, menor tasa de FN: primary alcanza $\approx 70\%$, mientras tertiary baja a $\approx 49\%$ y unknown a $\approx 45\%$. El modelo detecta mejor a los clientes con educación superior.
- **marital:** Las diferencias son moderadas. Los clientes divorciados presentan la mayor tasa de FN ($\approx 62\%$), seguidos de casados ($\approx 55\%$) y solteros ($\approx 52\%$). Ninguna categoría queda muy por debajo del promedio.

- **poutcome:** Es el patrón más extremo y accionable. Los clientes con campaña previa exitosa (`success`) tienen una tasa de FN prácticamente nula ($\approx 1\%$), mientras que `unknown` ($\approx 70\%$) y `failure` ($\approx 63\%$) concentran la mayoría de los errores. El modelo identifica casi perfectamente a los clientes con historial positivo, pero falla con aquellos sin información de campaña previa.

Conclusión operacional: Los segmentos más difíciles para el modelo son clientes con ocupaciones manuales o independientes, educación primaria y sin historial de campaña previo (`poutcome = unknown`). Para estos subgrupos, estrategias complementarias al modelo — como reglas de negocio basadas en balance o temporalidad podrían recuperar parte de las oportunidades perdidas. Por el contrario, los clientes con `poutcome = success` no requieren mejora: el modelo ya los captura con alta fiabilidad.

7 Discusión

7.1 ¿Cuál es el mejor modelo y por qué?

El mejor modelo es **LightGBM con `is.unbalance=True` y umbral 0.689**. La selección se basa en evidencia acumulada en tres capas experimentales:

- **Capa 1 (Entrega 2):** LightGBM supera a Logistic Regression y Random Forest en ROC-AUC en 5-fold CV (0.787 vs. 0.781 vs. 0.763).
- **Capa 3 (Entrega 2):** LightGBM + `class_weight` tiene el mayor F1 entre nueve configuraciones (0.4535), superando a LightGBM + SMOTE (0.3822) con una diferencia de 0.071 en F1.
- **Evaluación final (Entrega 3):** ROC-AUC = 0.7871 y F1 = 0.4787 sobre test independiente, con coherencia total respecto a CV (sin evidencia de *overfitting*).

7.2 ¿Qué tan confiables son los resultados?

Fortalezas de confiabilidad:

- Desviación estándar entre pliegues < 0.005 en ROC-AUC: el modelo es estable ante distintas particiones del conjunto de entrenamiento.
- Coherencia entre CV y test: $\Delta \text{ROC-AUC} = +0.004$; no hay evidencia de fuga de datos ni sobreajuste al proceso de validación.
- Todas las decisiones metodológicas están registradas y son auditables (Tabla 3).

- El experimento de *data leakage* cuantifica el riesgo con evidencia empírica (+18.7 pp de ROC-AUC inflado con *duration*).

Limitación principal: objetivo no alcanzado. El objetivo de ROC-AUC > 0.85 no se alcanzó: el modelo final obtuvo 0.787, quedando -0.063 pp por debajo. Las curvas de aprendizaje (Figura 6) indican que este techo está determinado por la **calidad informacional de las *features* disponibles**, no por la cantidad de datos ni por el algoritmo. Sin búsqueda de hiperparámetros y sin *feature engineering* adicional, el límite empírico del enfoque actual se estima en ROC-AUC ≈ 0.79 – 0.81 .

7.3 ¿Qué variables o patrones explican el desempeño?

El análisis SHAP (Sección 4) identifica tres patrones centrales:

1. **El historial de interacción previa es el predictor más accionable.** `poutcome_success` y `pdays` indican que un cliente que respondió bien en una campaña anterior es el mejor candidato para la siguiente. La estrategia de recontacto informado puede ser significativamente más rentable que campañas masivas.
2. **La fatiga de campaña reduce la probabilidad de aceptación.** `campaign` (contactos actuales) tiene efecto negativo creciente. Contactar repetidamente a un cliente que no responde reduce, en lugar de aumentar, su propensión a aceptar.
3. **El canal de contacto y la información disponible importan.** `contact_unknown` es la variable de mayor impacto global. Los clientes sin tipo de contacto registrado tienen características distintas y son sistemáticamente menos propensos a aceptar.

8 Conclusiones y Recomendaciones

8.1 Conclusiones del proyecto

1. **La segmentación supera al volumen de contactos.** Más contactos en la campaña actual reduce la tasa de conversión (confirmado por SHAP y por el análisis de FN). Contactar menos pero a los clientes correctos es estratégicamente más eficiente.
2. **El historial es el mejor predictor disponible.** Clientes con `poutcome = success` tienen tasas de aceptación muy superiores al promedio global (12%). Un sistema de priorización basado en historial previo puede entregar retorno positivo con el modelo actual.
3. **El *data leakage* es un riesgo real y cuantificable.** Incluir `duration` infla artificialmente el ROC-AUC en ≈ 0.15 puntos. En producción, esto llevaría a desplegar un modelo con desempeño irreal e inútil para tomar decisiones previas al contacto.

4. **La *accuracy* es una métrica engañosa con desbalance.** El `DummyClassifier` obtiene 88.3% de *accuracy* sin aprender nada. ROC-AUC y F1-score son las métricas apropiadas para este tipo de problema.
5. **El objetivo cuantitativo no se alcanzó con las *features* disponibles.** ROC-AUC > 0.85 requeriría búsqueda de hiperparámetros, *feature engineering* o datos adicionales. Esto es una conclusión honesta y técnicamente informativa: establece el límite empírico del enfoque actual.

8.2 ¿Qué haría falta para mejorar la solución?

Mejora	Descripción		Impacto esperado
Búsqueda de hiperparámetros	de	Optuna o GridSearchCV sobre <code>n_estimators</code> , <code>max_depth</code> , <code>learning_rate</code> , <code>num_leaves</code>	+3–8 pp en ROC-AUC
Feature engineering		<code>contacted_before</code> de <code>pdays</code> , <code>ratios</code> campaña/previos, <code>interacciones</code> <code>month</code> × <code>contact</code>	+2–5 pp en ROC-AUC
Calibración de probabilidades	de	<code>CalibratedClassifierCV</code> para mejorar la calidad de los scores	Mejor ajuste del umbral
Para desplegar			
Serialización del pipeline	del	<code>joblib</code> o <code>mlflow</code> para trazabilidad de versiones	Reproducibilidad en producción
Monitoreo de <i>data drift</i>		Detectar si el perfil de clientes en producción difiere del entrenamiento	Evitar degradación silenciosa
Validación temporal		Dataset 2008–2013; revalidar con datos más recientes antes de desplegar	Garantía de validez actual
Análisis de costo-beneficio		Estimar valor económico de FN (oportunidad perdida) vs FP (llamada innecesaria) para ajustar umbral con criterio financiero real	Umbral óptimo según negocio
Revisión de equidad (<i>fairness</i>)		Verificar que el modelo no discrimine por <code>age</code> , <code>marital</code> o <code>education</code>	Responsabilidad algorítmica

Cuadro 11: Hoja de ruta para mejorar y desplegar la solución

Referencias

- [1] Moro, S., Cortez, P., y Rita, P. (2014). *A Data-Driven Approach to Predict the Success of Bank Telemarketing*. *Decision Support Systems*, 62, 22–31.
- [2] UCI Machine Learning Repository. *Bank Marketing Dataset*. <https://archive.ics.uci.edu/ml/datasets/Bank+Marketing>
- [3] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. *Journal of Machine Learning Research*, 12, 2825–2830.
- [4] Ke, G. et al. (2017). *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. *Advances in Neural Information Processing Systems*, 30.
- [5] Lundberg, S. y Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. *Advances in Neural Information Processing Systems*, 30.
- [6] James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer.
- [7] Lemaître, G., Nogueira, F., y Aridas, C. (2017). *Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets*. *Journal of Machine Learning Research*, 18(17), 1–5.