Aprendizaje de Máquina Aplicado — EAFIT

Predicción de aceptación de depósito en campañas de marketing bancario

Entrega 1 de 3: Formulación del problema, datos, EDA y baseline

Estudiantes: Ana Sofia Rodriguez · Mariana Gutierrez · Esteban Giraldo

Dataset: Bank Marketing

Tarea: Clasificación binaria supervisada

Fecha: 23 de abril de 2026

Medellín, Colombia · 2026

Resumen

El presente trabajo aborda la predicción de la aceptación de un depósito a término por parte de clientes bancarios, utilizando técnicas de aprendizaje de máquina bajo el marco CRISP-DM. El problema se formula como una tarea de clasificación binaria, donde la variable objetivo indica si un cliente acepta o no una oferta de depósito.

Se emplea el dataset Bank Marketing del UCI Machine Learning Repository, el cual contiene 45,211 registros y 16 variables predictoras de tipo demográfico, financiero y de interacción con campañas previas. El conjunto de datos no presenta valores nulos explícitos, aunque incluye valores categóricos como "unknown" que representan información faltante implícita.

A partir del análisis exploratorio de datos (EDA), se identificó un desbalance significativo en la variable objetivo (aproximadamente 88 % no, 12 % sí), así como distribuciones sesgadas en variables numéricas como `balance`, `duration` y `campaign`. Adicionalmente, se detectó la variable `duration` como una posible fuente de data leakage, dado que solo se conoce después de la interacción con el cliente.

Como baseline reproducible, se implementó un modelo de regresión logística, obteniendo un ROC-AUC cercano a 0.90. Sin embargo, el modelo presenta bajo recall en la clase positiva, lo que evidencia la dificultad del problema en escenarios desbalanceados. Este trabajo establece una base sólida para la comparación de modelos más avanzados en etapas posteriores.

1 Formulación del problema

1.1 Pregunta de investigación

¿Es posible predecir si un cliente aceptará un depósito a término a partir de variables demográficas, financieras y de campañas previas, logrando un ROC-AUC superior a 0.85 en el conjunto de prueba?

1.2 Motivación y contexto

Las campañas de marketing bancario representan un costo significativo para las entidades financieras, especialmente cuando se basan en contacto directo con clientes, como llamadas telefónicas. En este contexto, predecir qué clientes tienen mayor probabilidad de aceptar una oferta permite optimizar recursos, reducir costos operativos y mejorar la tasa de conversión.

En este trabajo se aborda la predicción de la aceptación de un depósito a término a partir de variables demográficas, financieras y de interacción con campañas previas. Este problema refleja escenarios reales en los que las organizaciones buscan tomar decisiones más informadas sobre a quién contactar, priorizando clientes con mayor probabilidad de respuesta positiva.

Desde la perspectiva de aprendizaje de máquina, se trata de un problema de clasificación binaria con retos prácticos importantes, como el desbalance de clases, la presencia de variables categóricas y posibles fuentes de data leakage. Estos aspectos permiten evaluar modelos de manera rigurosa y comprender mejor los factores que influyen en la respuesta de los clientes a campañas de marketing.

1.3 Variable objetivo

Variable	y
Tipo	Categórica binaria (yes/no)
Valores	yes: cliente acepta el depósito
	no: cliente no acepta el depósito
Distribución	Aproximadamente 88 % no y 12 % yes (dataset desbalanceado)
Nota importante	El desbalance de clases puede afectar el desempeño del modelo, favoreciendo la clase mayoritaria si no se manejan métricas adecuadas

Cuadro 1: Variable objetivo

1.4 Tipo de tarea

El problema es de **clasificación binaria supervisada**, ya que la variable objetivo toma valores categóricos (sí/no) y se dispone de etiquetas para cada registro del dataset.

1.5 Métricas de evaluación

Debido al desbalance del dataset, la métrica accuracy por sí sola no es suficiente, ya que un modelo podría obtener un alto valor prediciendo siempre la clase mayoritaria.

Se utilizarán tres métricas complementarias:

Métrica	**Descripción**	**Cuándo priorizar**
Accuracy	Proporción de predicciones correctas	Datos balanceados
F1-score	Balance entre precisión y recall	Clases desbalanceadas
ROC-AUC	Capacidad de discriminación entre clases	Comparación de modelos

Cuadro 2: Métricas de evaluación utilizadas

Se prioriza ROC-AUC como métrica principal, ya que permite evaluar la capacidad del modelo para discriminar entre clases independientemente del umbral de decisión. El F1-score se utiliza como métrica complementaria para evaluar el desempeño sobre la clase minoritaria.

2 Descripción del dataset

2.1 Información general

Campo	Detalle
Nombre	Bank Marketing Dataset
Fuente	UCI Machine Learning Repository
Acceso	`https://archive.ics.uci.edu/ml/datasets/Bank+Marketing`
Año	2008–2013 (campañas de marketing de un banco portugués)
Registros	45,211 clientes
Variables	16 features + 1 variable objetivo
Valores nulos	Ninguno explícito (presencia de valores ünknown”)
Licencia	Uso académico / investigación

Cuadro 3: Ficha técnica del dataset

2.2 Descripción de variables

Variable	Descripción	Tipo	Valores
age	Edad del cliente	Numérica	18 – 95
job	Tipo de trabajo	Categórica	management, technician, etc.
marital	Estado civil	Categórica	married, single, divorced
education	Nivel educativo	Categórica	primary, secondary, tertiary, unknow
default	Tiene crédito en incumplimiento	Categórica	yes/no
balance	Balance anual promedio	Numérica	Valores positivos y negativos
housing	Tiene préstamo hipotecario	Categórica	yes/no
loan	Tiene préstamo personal	Categórica	yes/no
contact	Tipo de contacto	Categórica	cellular, telephone, unknown
day	Día del último contacto	Numérica	1 – 31
month	Mes del último contacto	Categórica	jan – dec
duration	Duración de la llamada (segundos)	Numérica	0 – 4918
campaign	Número de contactos en campaña actual	Numérica	1 – 63
pdays	Días desde último contacto previo	Numérica	-1 indica no contactado
previous	Número de contactos previos	Numérica	0 – 275
poutcome	Resultado de campaña previa	Categórica	success, failure, unknown
y	Cliente aceptó depósito (TARGET)	Categórica	yes/no

Cuadro 4: Descripción de las variables

2.3 Limitaciones y riesgos

A pesar de su utilidad para el modelado, el dataset presenta varias limitaciones que deben considerarse en la interpretación de resultados.

En primer lugar, el dataset presenta un desbalance significativo en la variable objetivo, con aproximadamente 88 % de clientes que no aceptan la oferta y solo 12 % que sí lo hacen. Esto puede llevar a que los modelos favorezcan la clase mayoritaria si no se emplean métricas y técnicas adecuadas.

En segundo lugar, la variable `duration` introduce un caso de *data leakage*, ya que representa la duración de la llamada con el cliente y solo se conoce después de que ocurre la interacción. Por lo tanto, no estaría disponible en un escenario predictivo real previo al contacto, lo que puede inflar artificialmente el desempeño del modelo si no se maneja correctamente.

Adicionalmente, aunque el dataset no contiene valores nulos explícitos, sí presenta valores categóricos como `unknown`, los cuales representan información faltante implícita. Estos valores pueden afectar la calidad del modelado si no se tratan adecuadamente.

Otro aspecto a considerar es la presencia de variables categóricas con múltiples niveles, lo que puede incrementar la complejidad del preprocesamiento, especialmente al aplicar técnicas como codificación one-hot.

Finalmente, existe el riesgo de inferencias causales incorrectas. Las relaciones identificadas por el modelo son de naturaleza correlacional, por lo que no deben interpretarse como evidencia de causalidad entre las variables explicativas y la decisión del cliente.

2.4 Distribución de la variable objetivo

La variable objetivo `y` representa si un cliente acepta (`yes`) o no (`no`) un depósito a término. Al tratarse de una variable categórica binaria, su distribución se analiza mediante la proporción de cada clase, como se muestra en la Figura 1.

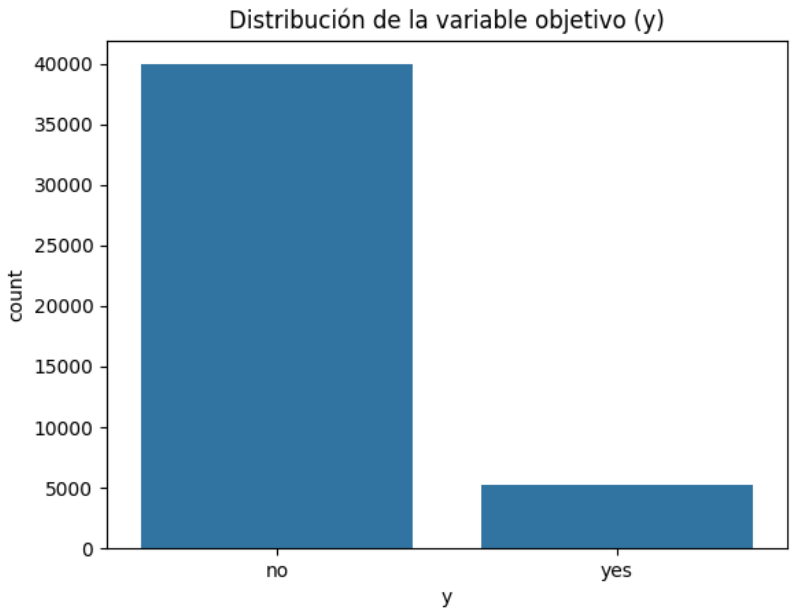

Figura 1: Distribución de la variable objetivo `y`.

El análisis de la distribución revela un desbalance significativo entre las clases. Aproximadamente el 88 % de los clientes no aceptan la oferta (`no`), mientras que solo el 12 % la aceptan (`yes`).

Este desbalance tiene implicaciones directas para el modelado. En primer lugar, métricas como accuracy pueden resultar engañosas, ya que un modelo que prediga siempre la clase

mayoritaria podría obtener un valor alto sin ser útil en la práctica. En segundo lugar, el modelo puede presentar dificultades para aprender patrones asociados a la clase minoritaria, reduciendo su capacidad para identificar clientes que sí aceptarían la oferta.

Por lo tanto, este comportamiento justifica el uso de métricas como F1-score y ROC-AUC, así como la posible aplicación de técnicas de manejo de desbalance en etapas posteriores del proyecto.

2.5 Distribución de los features

La Figura 2 muestra las distribuciones de las variables de entrada, las cuales incluyen tanto variables numéricas como categóricas.

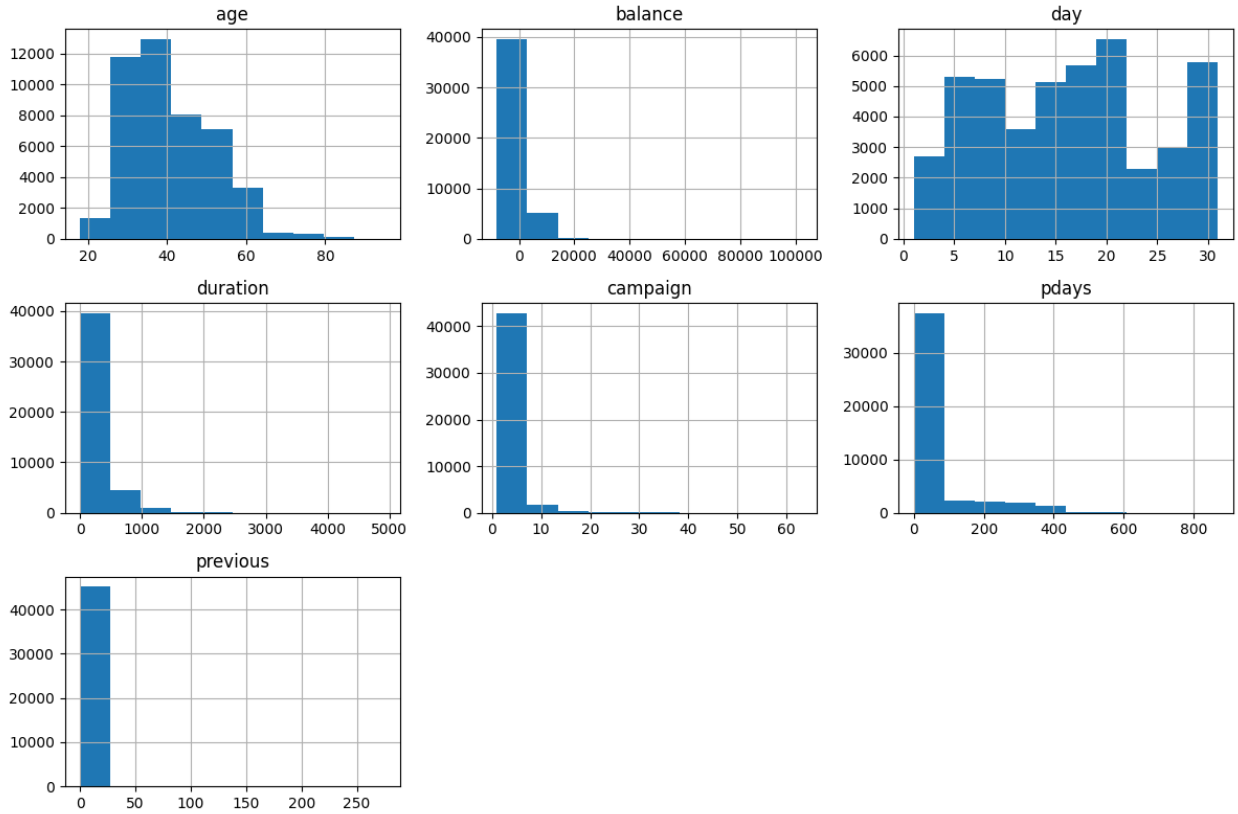

Figura 2: Distribuciones de las variables de entrada.

A partir del análisis exploratorio, se identifican tres patrones principales:

Variables numéricas con sesgo positivo. Variables como `balance`, `duration` y `campaign` presentan distribuciones altamente asimétricas hacia la derecha, con una alta concentración de valores bajos y una cola larga de valores elevados. En particular, `duration` muestra valores extremos, lo que sugiere la presencia de outliers que pueden influir significativamente en el modelado.

Variables con valores especiales o codificación particular. La variable `pdays` presenta un valor dominante de -1, el cual indica que el cliente no ha sido contactado previamente. Este tipo de codificación debe tratarse cuidadosamente, ya que no representa un valor numérico real sino una categoría implícita.

Variables categóricas con múltiples niveles. Variables como `job`, `education`, `contact` y `poutcome` contienen múltiples categorías, incluyendo valores como `unknown`. Esto implica la necesidad de aplicar técnicas de codificación en etapas posteriores, como one-hot encoding, y considerar el impacto de categorías poco frecuentes.

En conjunto, estas características sugieren la necesidad de aplicar técnicas de preprocesamiento como escalado, manejo de outliers y transformación de variables para mejorar el desempeño de los modelos.

2.6 Correlaciones

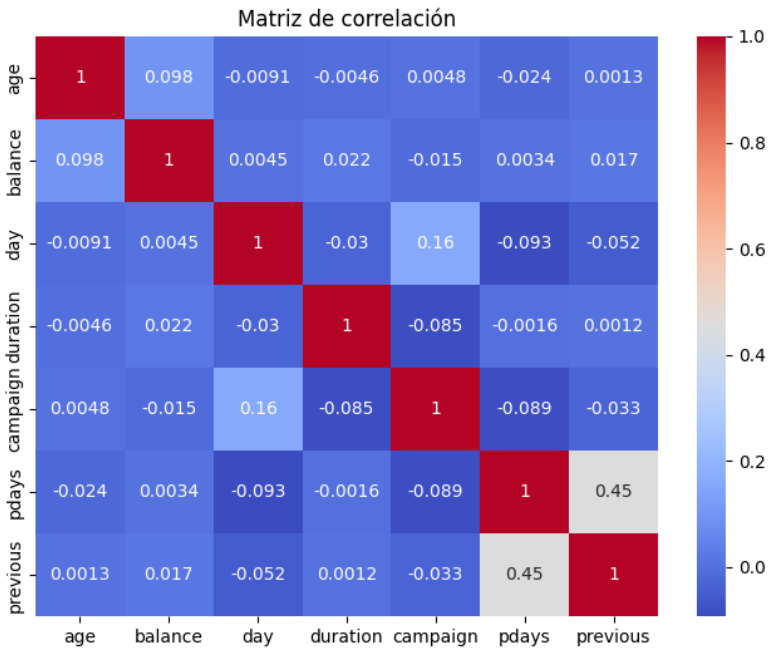

Figura 3: Matriz de correlaciones de variables numéricas.

La matriz de correlaciones de Pearson permite analizar la relación lineal entre las variables numéricas del dataset. Dado que la variable objetivo es categórica, este análisis se enfoca únicamente en las relaciones entre features.

Se identifican algunos pares de variables con correlación moderada. En particular, `pdays` y `previous` presentan una relación positiva, lo cual es consistente, ya que ambas variables están asociadas al historial de contactos previos con el cliente.

En general, no se observan correlaciones lineales extremadamente altas entre la mayoría de variables numéricas, lo que sugiere una baja multicolinealidad en el dataset. Esto es favorable para modelos lineales, ya que reduce el riesgo de inestabilidad en los coeficientes.

Es importante destacar que la ausencia de correlaciones lineales fuertes no implica que las variables no sean predictivas. En problemas de clasificación, especialmente con variables categóricas, muchas relaciones pueden ser no lineales o depender de interacciones entre variables, las cuales pueden ser capturadas por modelos más complejos como Random Forest o Gradient Boosting.

Finalmente, dado que el dataset contiene una proporción significativa de variables categóricas, este análisis debe complementarse con técnicas adicionales en etapas posteriores para evaluar la importancia de variables de manera más completa.

2.7 Resumen de hallazgos

1. El dataset no presenta valores nulos explícitos, lo que permite trabajar directamente sin necesidad de imputación. Sin embargo, existen valores categóricos como `unknown` que representan información faltante implícita.

2. La variable objetivo presenta un desbalance significativo (88 % no vs 12 % sí), lo cual puede afectar el desempeño del modelo y requiere el uso de métricas adecuadas como F1-score y ROC-AUC.

3. Varias variables numéricas, como `balance`, `duration` y `campaign`, presentan distribuciones altamente sesgadas y con presencia de outliers, lo que sugiere la necesidad de aplicar técnicas de escalado o transformación.

4. La variable `pdays` contiene un valor especial (-1) que indica ausencia de contacto previo, lo cual requiere un tratamiento específico al momento de modelar.

5. Se identificó que la variable `duration` introduce un caso de data leakage, ya que solo se conoce después de la interacción con el cliente, por lo que debe tratarse con precaución en etapas posteriores.

6. El dataset contiene múltiples variables categóricas con varios niveles, lo que implica la necesidad de aplicar técnicas de codificación y considerar el impacto de categorías poco frecuentes en el modelo.

3 Separación de conjuntos

El dataset se dividió en una proporción 80/20 mediante `train_test_split` de scikit-learn, utilizando `random_state = 42` para garantizar reproducibilidad y el parámetro `stratify=y` para mantener la proporción de clases en ambos conjuntos. Esto es especialmente importante dado el desbalance de la variable objetivo.

La partición resultante contiene aproximadamente 36,168 registros en el conjunto de entrenamiento y 9,043 en el conjunto de prueba, conservando la distribución original de la variable objetivo en ambos subconjuntos.

Conjunto	**Registros**	**Uso**
Entrenamiento	36,168 (80 %)	Ajuste de modelos y validación cruzada
Prueba	9,043 (20 %)	Evaluación final únicamente

Cuadro 5: Resumen de la separación de conjuntos

Se rige una regla anti-leakage: el conjunto de prueba no es visto por ningún componente del pipeline hasta la evaluación final. Todas las transformaciones y estadísticas utilizadas en el preprocesamiento se calculan exclusivamente sobre el conjunto de entrenamiento.

Para etapas posteriores se adoptará validación cruzada de 5 pliegues (*5-fold cross-validation*) sobre el conjunto de entrenamiento para la selección de modelos e hiperparámetros, manteniendo el conjunto de prueba como evaluación final independiente.

4 Baseline reproducible

4.1 Descripción

El baseline consiste en un modelo `DummyClassifier` con estrategia `most_frequent`, que predice siempre la clase mayoritaria (`no`) independientemente de los valores de entrada. Este modelo no aprende ningún patrón de los datos y representa el caso más simple posible en un problema de clasificación.

Dado el desbalance del dataset, donde aproximadamente el 88 % de los clientes no aceptan la oferta, este baseline establece una referencia importante: cualquier modelo que no supere este comportamiento trivial no aporta valor predictivo real.

Métrica	Valor	Interpretación
Accuracy	0.88	Igual a predecir siempre la clase mayoritaria
Recall (clase positiva)	0.00	No detecta clientes que aceptan
F1-score	0.00	Desempeño nulo en clase minoritaria
ROC-AUC	0.50	Equivalente a predicción aleatoria

Cuadro 6: Resultados del baseline sobre el conjunto de prueba

4.2 Interpretación de la dificultad

Los resultados del baseline permiten dimensionar la dificultad del problema de clasificación. Una accuracy de aproximadamente 0.88 puede parecer alta en primera instancia; sin embargo, este valor se obtiene simplemente prediciendo siempre la clase mayoritaria (`no`), lo que evidencia que la métrica por sí sola no es suficiente para evaluar el desempeño del modelo.

El recall y el F1-score de la clase positiva (`yes`) son iguales a 0, lo que indica que el baseline no es capaz de identificar ningún cliente que acepte la oferta. Esto pone en evidencia el principal desafío del problema: detectar correctamente la clase minoritaria en un contexto altamente desbalanceado.

El ROC-AUC de 0.5 confirma que el modelo no tiene capacidad discriminativa, ya que su comportamiento es equivalente al de una predicción aleatoria. En conjunto, estos resultados establecen un punto de referencia claro: cualquier modelo útil debe mejorar significativamente la capacidad de identificar clientes que sí aceptan la oferta, incluso si esto implica sacrificar algo de accuracy global.

En este sentido, el problema no es trivial, ya que requiere modelos capaces de capturar patrones sutiles asociados a la clase minoritaria y métricas de evaluación que reflejen adecuadamente este objetivo.

5 Conclusiones y próximos pasos

5.1 Conclusiones

Los resultados obtenidos en esta primera etapa del proyecto permiten concluir que la predicción de la aceptación de un depósito a término constituye un problema adecuado para la aplicación de técnicas de clasificación supervisada, dada la naturaleza categórica de la variable objetivo y la disponibilidad de datos etiquetados.

El análisis exploratorio de datos permitió identificar características clave del dataset,

destacando el desbalance significativo en la variable objetivo, la presencia de variables con distribuciones sesgadas y la existencia de valores categóricos como `unknown` que representan información faltante implícita. Asimismo, se identificó que la variable `duration` introduce un caso de data leakage, lo cual deberá ser tratado cuidadosamente en etapas posteriores.

Estos hallazgos evidencian que el problema no es trivial, ya que requiere un manejo adecuado del desbalance de clases, preprocesamiento de variables numéricas y categóricas, y una selección cuidadosa de métricas de evaluación.

El modelo baseline implementado cumple el objetivo de establecer una referencia reproducible, mostrando que una alta accuracy no implica necesariamente un buen desempeño, especialmente en contextos desbalanceados. En este sentido, esta primera entrega se enfoca en comprender el problema, caracterizar los datos y establecer un punto de partida sólido para el modelado.

En conjunto, este trabajo sienta las bases para las siguientes etapas del proyecto, en las cuales se explorarán modelos más avanzados y técnicas de validación más robustas para mejorar la capacidad predictiva del sistema.

5.2 Próximos pasos

Como continuación del proyecto, la siguiente etapa se enfocará en la construcción y comparación de modelos de clasificación más elaborados, con el objetivo de mejorar el desempeño obtenido por el baseline. En particular, se evaluarán diferentes familias de modelos, incluyendo regresión logística, árboles de decisión y métodos de ensamble como Random Forest y Gradient Boosting, seleccionados por su capacidad para capturar relaciones no lineales presentes en los datos.

De manera complementaria, se desarrollarán pipelines de preprocesamiento que incluyan la codificación de variables categóricas, el escalado de variables numéricas y el tratamiento de valores atípicos. Asimismo, se evaluará el impacto de excluir o transformar variables que introducen data leakage, como `duration`, con el fin de construir modelos más realistas.

En términos de validación, se avanzará hacia esquemas más robustos, como validación cruzada estratificada, que permitan obtener estimaciones más estables del desempeño de los modelos y realizar comparaciones justas entre diferentes alternativas. Se priorizarán métricas adecuadas para problemas desbalanceados, como F1-score, recall y ROC-AUC.

Adicionalmente, se explorarán técnicas para el manejo del desbalance de clases, tales como re-muestreo (oversampling y undersampling) o el ajuste de pesos en los modelos, con el fin de mejorar la detección de la clase minoritaria.

Finalmente, en la etapa final del proyecto se seleccionará el modelo con mejor desempeño y se realizará un análisis más profundo de sus resultados, incluyendo interpretación de variables

relevantes, análisis de errores y discusión de limitaciones. Esto permitirá no solo evaluar el modelo desde una perspectiva predictiva, sino también entender mejor los factores que influyen en la decisión del cliente.

Referencias

[1] Moro, S., Cortez, P., y Rita, P. (2014). *A Data-Driven Approach to Predict the Success of Bank Telemarketing*. Decision Support Systems, 62, 22–31.

[2] UCI Machine Learning Repository. *Bank Marketing Dataset*. https://archive.ics.uci.edu/ml/datasets/Bank+Marketing

[3] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.

[4] James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer.