

Aprendizaje de Máquina Aplicado — EAFIT

Predicción de aceptación de depósito en campañas de marketing bancario

Entrega 1 de 3: Formulación del problema, datos, EDA y baseline

Estudiantes: Ana Sofia Rodriguez · Mariana Gutierrez · Esteban Giraldo

Dataset: Bank Marketing

Tarea: Clasificación binaria supervisada

Fecha: 23 de abril de 2026

Resumen

El presente trabajo aborda la predicción de la aceptación de un depósito a término por parte de clientes bancarios, utilizando técnicas de aprendizaje de máquina bajo el marco CRISP-DM. El problema se formula como una tarea de clasificación binaria, donde la variable objetivo indica si un cliente acepta o no una oferta de depósito.

Se emplea el dataset Bank Marketing del UCI Machine Learning Repository, el cual contiene 45,211 registros y 16 variables predictoras de tipo demográfico, financiero y de interacción con campañas previas. El conjunto de datos no presenta valores nulos explícitos, aunque incluye valores categóricos como **unknown** que representan información faltante implícita.

A partir del análisis exploratorio de datos (EDA), se identificó un desbalance significativo en la variable objetivo (aproximadamente 88 % **no**, 12 % **yes**), así como distribuciones sesgadas en variables numéricas como **balance**, **duration** y **campaign**. Adicionalmente, se detectó la variable **duration** como una fuente de *data leakage*, dado que solo se conoce después de la interacción con el cliente, por lo que se excluye del modelado.

Como baselines reproducibles se implementaron dos modelos: un **DummyClassifier** con estrategia **most_frequent**, que establece el piso absoluto de referencia (Accuracy ≈ 0.88 , F1 = 0.00, ROC-AUC = 0.50), y una Regresión Logística con pipeline completo, que constituye el baseline inteligente (ROC-AUC ≈ 0.90 , F1 ≈ 0.35). La diferencia entre ambos evidencia el potencial predictivo del problema y establece una referencia clara para la comparación de modelos en etapas posteriores.

Índice

1. Formulación del problema	3
1.1. Pregunta de investigación	3
1.2. Motivación y contexto	3
1.3. Variable objetivo	3
1.4. Tipo de tarea	4
1.5. Métricas de evaluación	4
2. Descripción del dataset	4
2.1. Información general	5
2.2. Descripción de variables	6
2.3. Limitaciones y riesgos	6
3. Análisis exploratorio de datos (EDA)	7
3.1. Distribución de la variable objetivo	7
3.2. Distribución de variables numéricas	8
3.3. Variables numéricas vs. variable objetivo	9
3.4. Variables categóricas vs. variable objetivo	9
3.5. Correlaciones entre variables numéricas	11
3.6. Resumen de hallazgos del EDA	12
4. Separación de conjuntos	12
5. Baseline reproducible	13
5.1. Descripción de los baselines	13
5.2. Resultados	13
5.3. Interpretación de la dificultad del problema	15
6. Conclusiones y próximos pasos	15
6.1. Conclusiones	15
6.2. Próximos pasos — Entrega 2	16

1 Formulación del problema

1.1 Pregunta de investigación

¿Es posible predecir si un cliente aceptará un depósito a término a partir de variables demográficas, financieras y de campañas previas, logrando un ROC-AUC superior a 0.85 en el conjunto de prueba?

1.2 Motivación y contexto

Las campañas de marketing bancario representan un costo significativo para las entidades financieras, especialmente cuando se basan en contacto directo con clientes mediante llamadas telefónicas. En este contexto, predecir qué clientes tienen mayor probabilidad de aceptar una oferta permite optimizar recursos, reducir costos operativos y mejorar la tasa de conversión.

Este trabajo aborda la predicción de la aceptación de un depósito a término a partir de variables demográficas, financieras y de interacción con campañas previas, reflejando escenarios reales en los que las organizaciones buscan tomar decisiones más informadas sobre a quién contactar, priorizando clientes con mayor probabilidad de respuesta positiva.

Desde la perspectiva de aprendizaje de máquina, se trata de un problema de clasificación binaria con retos prácticos importantes: desbalance de clases, presencia de variables categóricas y fuentes de *data leakage*. Estos aspectos permiten evaluar modelos de manera rigurosa y comprender mejor los factores que influyen en la respuesta de los clientes.

1.3 Variable objetivo

Variable	y
Tipo	Categórica binaria (yes/no)
Valores	yes : cliente acepta el depósito no : cliente no acepta el depósito
Distribución	Aproximadamente 88 % no y 12 % yes (dataset desbalanceado)
Nota importante	El desbalance puede hacer que el modelo favorezca la clase mayoritaria si no se emplean métricas adecuadas

Cuadro 1: Variable objetivo

1.4 Tipo de tarea

El problema es de **clasificación binaria supervisada**, ya que la variable objetivo toma valores categóricos (**yes/no**) y se dispone de etiquetas para cada registro del dataset.

1.5 Métricas de evaluación

Debido al desbalance del dataset, la métrica *accuracy* por sí sola no es suficiente: un modelo que prediga siempre la clase mayoritaria obtendría un valor alto sin aportar valor predictivo. Se utilizan tres métricas complementarias:

Métrica	Descripción	Rol en este proyecto
ROC-AUC	Capacidad de discriminación entre clases	Principal
F1-score	Balance entre precisión y recall	Complementaria (clase minoritaria)
Accuracy	Proporción de predicciones correctas	Solo referencia

Cuadro 2: Métricas de evaluación utilizadas

Se prioriza **ROC-AUC** como métrica principal porque evalúa la capacidad discriminativa del modelo independientemente del umbral de decisión y es robusta al desbalance de clases. El **F1-score** se emplea como métrica complementaria para monitorear el desempeño sobre la clase minoritaria (**yes**).

2 Descripción del dataset

2.1 Información general

Campo	Detalle
Nombre	Bank Marketing Dataset
Fuente	UCI Machine Learning Repository
Acceso	https://archive.ics.uci.edu/ml/datasets/Bank+Marketing
Período	2008–2013 (campañas de un banco portugués)
Registros	45,211 clientes
Variables	15 features + 1 variable objetivo (y)
Nota	duration excluida del modelado por <i>data leakage</i>
Valores nulos	Ninguno explícito (presencia de valores unknown)
Licencia	Uso académico / investigación

Cuadro 3: Ficha técnica del dataset

2.2 Descripción de variables

Variable	Descripción	Tipo	Valores / Rango
age	Edad del cliente	Numérica	18–95
job	Tipo de trabajo	Categórica	management, technician, etc.
marital	Estado civil	Categórica	married, single, divorced
education	Nivel educativo	Categórica	primary, secondary, tertiary, unknown
default	Crédito en incumplimiento	Categórica	yes/no
balance	Balance anual promedio (EUR)	Numérica	Positivos y negativos
housing	Préstamo hipotecario	Categórica	yes/no
loan	Préstamo personal	Categórica	yes/no
contact	Tipo de contacto	Categórica	cellular, telephone, unknown
day	Día del último contacto	Numérica	1–31
month	Mes del último contacto	Categórica	jan–dec
duration	Duración de la llamada (seg.) — leakage	Numérica	0–4,918
campaign	Contactos en campaña actual	Numérica	1–63
pdays	Días desde último contacto previo	Numérica	–1 = no contactado
previous	Contactos en campañas previas	Numérica	0–275
poutcome	Resultado de campaña previa	Categórica	success, failure, unknown
y	TARGET: cliente aceptó depósito	Categórica	yes/no

Cuadro 4: Descripción de las variables. **duration** se documenta pero se excluye del modelado.

2.3 Limitaciones y riesgos

Desbalance de clases. La variable objetivo presenta una distribución de aproximadamente 88 % **no** vs. 12 % **yes**. Esto puede llevar a que los modelos favorezcan la clase mayoritaria si no se emplean métricas y técnicas adecuadas.

Data leakage en duration. Esta variable representa la duración de la llamada con el cliente y solo se conoce después de que ocurre la interacción. No estaría disponible en un escenario predictivo real previo al contacto, por lo que se excluye desde la separación de conjuntos para evitar inflar artificialmente el desempeño.

Nulos implícitos. El dataset no contiene valores nulos explícitos, pero las variables `job`, `education`, `contact` y `poutcome` presentan la categoría `unknown`, que representa información faltante implícita y debe tratarse adecuadamente.

Codificación especial en `pdays`. El valor `-1` no es un dato numérico real sino que indica que el cliente no fue contactado previamente. Se tratará como una categoría implícita mediante la creación de un feature binario `contacted_before` en etapas posteriores.

Riesgo de inferencias causales. Las relaciones identificadas por el modelo son de naturaleza correlacional y no deben interpretarse como causalidad entre las variables explicativas y la decisión del cliente.

3 Análisis exploratorio de datos (EDA)

3.1 Distribución de la variable objetivo

La Figura 1 muestra la distribución de la variable objetivo `y`. El desbalance es significativo: aproximadamente el 88 % de los clientes no aceptan la oferta (`no`), mientras que solo el 12 % la aceptan (`yes`).




Figura 1: Distribución de la variable objetivo `y`.

Este desbalance tiene implicaciones directas para el modelado. Primero, métricas como *accuracy* pueden resultar engañosas. Segundo, el modelo puede presentar dificultades para aprender patrones asociados a la clase minoritaria, reduciendo su capacidad para identificar

clientes que sí aceptarían la oferta. Esto justifica el uso de ROC-AUC y F1-score como métricas principales.

3.2 Distribución de variables numéricas

La Figura 2 muestra las distribuciones de las variables numéricas del dataset. Se identifican tres patrones principales.




Figura 2: Distribuciones de las variables numéricas.

Sesgo positivo fuerte. Variables como `balance`, `duration` y `campaign` presentan distribuciones altamente asimétricas hacia la derecha, con alta concentración de valores bajos y colas largas de valores elevados, lo que sugiere la presencia de outliers.

Codificación especial en `pdays`. El valor `-1` es dominante e indica que el cliente no fue contactado previamente. No representa un valor numérico real sino una categoría implícita que requiere tratamiento específico.

Concentración de ceros en `previous`. La mayoría de clientes no registra contactos en campañas anteriores, lo que limita el poder predictivo de esta variable para gran parte del

dataset.

3.3 Variables numéricas vs. variable objetivo

La Figura 3 compara las distribuciones de las variables numéricas clave entre los clientes que aceptaron y los que no aceptaron la oferta.




Figura 3: Variables numéricas segmentadas por clase objetivo (yes/no).

Los resultados revelan que **duration** muestra la diferencia más marcada entre clases (confirmando su capacidad predictiva, pero también el leakage que impide su uso). **balance** y **previous** presentan diferencias moderadas, mientras que **campaign** indica que los clientes que aceptaron fueron contactados menos veces en promedio.

3.4 Variables categóricas vs. variable objetivo

La Figura 4 muestra la tasa de aceptación (% de **yes**) por categoría de las principales variables categóricas, comparada con el promedio global del 12%.




Figura 4: Tasa de aceptación (%) por variable categórica. La línea roja indica el promedio global (12%).

Las observaciones más relevantes son:

- **poutcome = success**: tasa de aceptación muy superior al promedio global, siendo la categoría con mayor poder predictivo.
- **month**: los meses de marzo, septiembre y diciembre presentan tasas de aceptación notablemente más altas.
- **contact = unknown**: tasa de aceptación inferior al promedio; el tipo de contacto registrado tiene relevancia predictiva.

- `education` y `job`: presentan variaciones moderadas, con categorías como `tertiary` y `management` mostrando tasas ligeramente superiores.

3.5 Correlaciones entre variables numéricas




Figura 5: Matriz de correlaciones de Pearson — variables numéricas.

La matriz de correlaciones (Figura 5) muestra que las correlaciones lineales entre la mayoría de features son bajas, lo que indica poca multicolinealidad y condiciones favorables para modelos lineales. El par más correlacionado es `pdays`–`previous` ($r \approx 0,45$), consistente con que ambas variables miden el historial de contactos previos.

La correlación de `duration` con `y` es la más alta entre las variables numéricas ($r \approx 0,40$), confirmando tanto su poder predictivo como el riesgo de leakage. La ausencia de correlaciones lineales fuertes entre el resto de features y `y` no descarta relaciones no lineales, las cuales pueden ser capturadas por modelos basados en árboles.

3.6 Resumen de hallazgos del EDA

#	Hallazgo	Descripción	Implicación para el modelado
1	Desbalance	88 % no vs. 12 % yes	Usar ROC-AUC y F1 como métricas principales
2	Leakage	<code>duration</code> correlaciona fuertemente con <code>y</code>	Excluir desde la separación de conjuntos
3	Codificación	<code>pdays = 71</code> es categoría implícita	Crear feature binario <code>contacted_before</code>
4	Sesgo numérico	<code>balance</code> , <code>campaign</code> con sesgo positivo fuerte	Evaluar escalado o transformación logarítmica
5	Predictora clave	<code>poutcome = success</code> → alta aceptación	Variable potencialmente muy relevante
6	Nulos implícitos	<code>unknown</code> en 4 variables categóricas	Tratar como categoría propia o imputar
7	Baja multicolinealidad	Correlaciones lineales bajas entre features	Favorable para Regresión Logística

Cuadro 5: Resumen de hallazgos del EDA

4 Separación de conjuntos

El dataset se dividió en proporción 80/20 mediante `train_test_split` de scikit-learn, utilizando `random_state = 42` para garantizar reproducibilidad y el parámetro `stratify=y` para preservar la proporción de clases en ambos subconjuntos. La variable `duration` se excluye desde este punto.

Conjunto	Registros	Uso
Entrenamiento	36,168 (80 %)	Ajuste de modelos y validación cruzada
Prueba	9,043 (20 %)	Evaluación final únicamente

Cuadro 6: Resumen de la separación de conjuntos

Regla anti-leakage: el conjunto de prueba no es accedido por ningún componente del pipeline hasta la evaluación final. Todas las transformaciones (escalado, codificación) se cal-

culan exclusivamente sobre el conjunto de entrenamiento y se aplican al conjunto de prueba mediante el pipeline.

Para etapas posteriores se adoptará validación cruzada estratificada de 5 pliegues (*5-fold cross-validation*) sobre el conjunto de entrenamiento para la selección de modelos e hiperparámetros.

5 Baseline reproducible

5.1 Descripción de los baselines

Se implementan dos baselines para establecer referencias claras en distintos niveles:

Modelo	Descripción	Propósito
DummyClassifier (most_frequent)	Predice siempre la clase mayoritaria (no)	Piso absoluto
LogisticRegression	Modelo lineal simple con pipeline completo	Baseline inteligente

Cuadro 7: Baselines implementados

El pipeline de la Regresión Logística incluye: `StandardScaler` para variables numéricas y `OneHotEncoder` (con `handle_unknown='ignore'`) para variables categóricas, ambos ajustados exclusivamente sobre el conjunto de entrenamiento.

5.2 Resultados

Modelo	Accuracy	F1-score	ROC-AUC
DummyClassifier (most_frequent)	≈ 0.88	0.00	0.50
Logistic Regression	≈ 0.90	≈ 0.35	≈ 0.90

Cuadro 8: Comparación de métricas sobre el conjunto de prueba




Figura 6: Matriz de confusión — Regresión Logística (baseline inteligente).




Figura 7: Comparación de métricas entre los dos baselines.

5.3 Interpretación de la dificultad del problema

El `DummyClassifier` alcanza una *accuracy* de ≈ 0.88 simplemente prediciendo siempre no, evidenciando que esta métrica es inútil como criterio de evaluación en este contexto. Su F1-score de 0 y ROC-AUC de 0.50 confirman que no tiene capacidad discriminativa alguna.

La Regresión Logística mejora sustancialmente el ROC-AUC hasta ≈ 0.90 , lo que indica buena capacidad discriminativa global. Sin embargo, el F1-score de ≈ 0.35 sobre la clase positiva evidencia el principal desafío del problema: **detectar correctamente la clase minoritaria (yes) en un contexto altamente desbalanceado**. Muchos clientes que sí aceptarían la oferta son clasificados erróneamente como no (falsos negativos), lo que reduce el valor práctico del modelo desde la perspectiva del negocio.

Esto confirma que el problema no es trivial y que se requerirán técnicas de manejo de desbalance (SMOTE, ajuste de pesos) y modelos más expresivos en la Entrega 2 para mejorar el recall en la clase positiva.

6 Conclusiones y próximos pasos

6.1 Conclusiones

Los resultados de esta primera etapa permiten concluir que la predicción de la aceptación de un depósito a término es un problema adecuado para clasificación supervisada, con una variable objetivo clara, métricas bien justificadas y suficiente riqueza en los datos para el modelado.

El EDA identificó características clave: desbalance significativo en `y`, distribuciones sesgadas en variables numéricas, valores `unknown` como nulos implícitos, la variable `duration` como fuente de leakage y `poutcome` como el predictor categórico más prometedor.

Los dos baselines implementados cumplen objetivos distintos y complementarios: el `DummyClassifier` establece el piso absoluto de comparación (ROC-AUC = 0.50), mientras que la Regresión Logística establece el baseline inteligente (ROC-AUC ≈ 0.90). La brecha entre ambos confirma que el problema tiene potencial predictivo real; la brecha en F1 señala el trabajo pendiente para detectar correctamente la clase minoritaria.

6.2 Próximos pasos — Entrega 2

Acción	Justificación
Comparar 3 familias de modelos (LR, RF, XGBoost)	Cubrir modelos lineales y no lineales
Experimento con y sin <code>duration</code>	Cuantificar impacto del leakage como análisis de sensibilidad
Manejo de desbalance (SMOTE, <code>class_weight</code>)	Mejorar recall en la clase positiva
Validación cruzada estratificada 5-fold	Estimaciones de desempeño más estables
Ajuste de umbral de decisión	Optimizar F1 según objetivo de negocio
Feature engineering: <code>contacted_before</code>	Capturar la categoría implícita de <code>pdays = 1</code>

Cuadro 9: Próximos pasos para la Entrega 2

Referencias

- [1] Moro, S., Cortez, P., y Rita, P. (2014). *A Data-Driven Approach to Predict the Success of Bank Telemarketing*. *Decision Support Systems*, 62, 22–31.
- [2] UCI Machine Learning Repository. *Bank Marketing Dataset*. <https://archive.ics.uci.edu/ml/datasets/Bank+Marketing>
- [3] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. *Journal of Machine Learning Research*, 12, 2825–2830.
- [4] James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer.